HOCHSCHULE MITTWEIDA
University of Applied Sciences

BACHELORARBEIT

Herr Paul Fuchs

Die Downtime-freie Bereitstellung von Microservices in Kubernetes Umgebungen.

2026

Fakultät Angewandte Computer- und Biowissenschaften

BACHELORARBEIT

Die Downtime-freie Bereitstellung von Microservices in Kubernetes Umgebungen.

Autor:
Paul Fuchs

Seminargruppe:
MI20w2-B

Studiengang:
Medieninformatik und
Interaktives Entertainment

Erstprüfer:
Prof. Philipp Klimant

Zweitprüfer:
Dr. Beier-Grunwald

Einreichung:
Mittweida, den 27.03.2026

Bibliografische Angaben

Fuchs, Paul: Die Downtime-freie Bereitstellung von Microservices in Kubernetes Umgebungen. TODO: 5 Seiten, 14 Abbildungen, 1 Anlage mit Quelltexten, Hochschule Mittweida (FH), Fachbereich Angewandte Computer- und Biowissenschaften

Bachelorarbeit 2026

Abstract TODO

Inhaltsverzeichnis

1 Einleitung **1**

1.1 Problemstellung 1

1.2 Forschungsfrage 1

2 Theoretische Grundlagen **3**

2.1 Microservice Architektur 3

2.2 Microservice Orchestrierung mit Kubernetes 4

2.3 Deployment Strategien 4

2.3.1 Rolling Updates 4

2.3.2 Canary 5

2.4 Site Reliability Engineering und dessen Konzepte 5

2.5 Monitoring und Observability 5

3 Konzeption und Methodik **7**

3.1 Systemarchitektur 7

3.2 Theoretisches Modell 9

3.3 Parameter zur Analyse 9

3.3.1 Fehlerfreier Zustand des Systems 10

3.3.2 Fehlerszenario A 10

3.3.3 Fehlerszenario B 10

3.3.4 Analyseintervalle 10

4 Evaluation **13**

4.1 Analyse der injizierten Fehlerrate 13

4.1.1 Mittlere Detektionszeit und Mittlere Wiederherstellungszeit 13

4.1.2 Die einzelnen Testläufe im zeitlichen Verlauf 15

4.1.3 Die gemittelten Werte der Deployment Strategien im Vergleich 17

4.2 Analyse der injizierten Latenz 17

4.2.1 Mittlere Detektionszeit und Mittlere Wiederherstellungszeit 17

4.2.2 Die einzelnen Testläufe im zeitlichen Verlauf 18

4.2.3 Die gemittelten Werte der Deployment Strategien im Vergleich 20

4.3 Fehlerbudget Verbrauch pro Deployment Strategie 21

4.3.1 Fehlerszenario A 21

4.3.2 Fehlerszenario B 21

5 Diskussion **23**

5.1 Der erste Testlauf der injizierten Fehlerrate für das Canary Release mit globaler Metrikanalyse 23

5.2 Nicht gemessene Fehler während der ersten Canary Phase 23

5.3 Detektionszeit in Zusammenhang des Fehlerbudgetverbrauchs . . 24

6 Fazit **25**

6.1 Beantwortung der Forschungsfrage 25

6.2 Ausblick 25

A Eigenständigkeitserklärung **27**

Abbildungsverzeichnis

3.1 Systemarchitektur: EKS Cluster Versuchsaufbau 8

4.1 Summe der Zeit bis zur Detektion und der Zeit bis zur Wiederherstellung für injizierte Fehlerrate 14

4.2 Fehlerrate Rolling Update im Einzelvergleich 15

4.3 Fehlerrate Canary Release globaler Metrikanalyse im Einzelvergleich 16

4.4 Fehlerrate Canary Release isolierter Analysemetrik im Einzelvergleich 16

4.5 Fehlerrate unterschiedlicher Deployment Strategien 17

4.6 Summe der Zeit bis zur Detektion und der Zeit bis zur Wiederherstellung für injizierte Latenz 18

4.7 Latenz Rolling Update im Einzelvergleich 19

4.8 Latenz Canary Release globaler Metrikanalyse im Einzelvergleich 19

4.9 Latenz Canary Release isolierter Analysemetrik im Einzelvergleich 20

4.10 Latenzen unterschiedlicher Deployment Strategien 20

4.11 Verbrauch des Fehlerbudgets unterschiedlicher Deployment Strategien bei injizierter Fehlerrate über die Testdauer 21

4.12 Verbrauch des Fehlerbudgets unterschiedlicher Deployment Strategien bei injizierter Latenz über die Testdauer 22

Tabellenverzeichnis

Kapitel 1

Einleitung

1.1 Problemstellung

1.2 Forschungsfrage

In welchem Maß verringert ein Canary Release mit Service-Level-Objective basierten Analysen den Verbrauch des Fehlerbudgets im Vergleich zu Rolling Updates mit statischen Alerts? Diese Arbeit soll quantitativ analysieren, welcher Anteil des Fehlerbudgets bei der Wahl von Deployment Strategie und zugrunde liegender analysierter Metrik eingespart werden kann.

Kapitel 2

Theoretische Grundlagen

Den Titel in Zusammenhang mit der Forschungsfrage lesend, stellen sich zunächst einige Fragen. Was sind Microservices und wodurch zeichnen sie sich aus? Möglicherweise, Was ist Kubernetes? Was ist die Bereitstellung eben jener Microservices? Weiter stellen sich die Fragen, Was sind Service-Level-Objectives, Was ist das Fehlerbudget, Was ist Downtime und zuletzt, Wie kann das alles gemessen werden. Die folgenden Abschnitte beantworten diese Fragen und führen zum Versuchsaufbau hin.

2.1 Microservice Architektur

James Lewis und Martin Fowler beschrieben bereits 2014 Microservice Architekturen und grenzten dabei den Architekturansatz klar von monolithischen Anwendungen ab. In aller Kürze beschreiben die Microservice Architektur als Ansatz bei dem eine Anwendung aus dem Verbund mehrerer Services besteht, von denen jeder als eigener Prozess läuft und deren Kommunikation über leichtgewichtige Mechanismen, bspw. HTTP-Ressource API's stattfindet. Dabei werden die Services auf Geschäftsprozesse zugeschnitten und lassen sich unabhängig voneinander testen, bereitstellen und skalieren. Weiter beschreiben sie für Microservice Architekturen die folgenden Charakteristika:

- Komponenten durch Services
- Organisierung anhand der Geschäftsprozesse
- Produkte, keine Projekte

- Schlaue Endpunkte und Nachrichtendepots
- Dezentrale Steuerung
- Dezentrales Datenmanagement
- Automatisierung der Infrastruktur
- Fehlertoleranz
- Evolutionäres Design

Diese Charakteristika lassen sich Ihrer Aussage nach bei den meisten Microservice Architekturen finden, sind jedoch nicht allgemeingültig oder als Definition zu Verstehen. (Vgl. [**Fowler2014**])

2.2 Microservice Orchestrierung mit Kubernetes

2.3 Deployment Strategien

Die Autoren der Argo-Rollouts Dokumentation listen die gängigsten Deployment Strategien in ihren Konzepten auf, dazu gehören Rolling, Recreate, Blue-Green und Canary.(Vgl. [**ArgoRolloutsDeployStrat2026**]) Im folgenden werden die für diese Arbeit wichtigen Strategien erklärt.

2.3.1 Rolling Updates

Die Kubernetes Autoren beschreiben die Standard-Strategie eines Deployment Objektes sinngemäß so, dass die Pods einer nach dem anderen ausgetauscht werden. (Vgl. [**K8sRolling**]) Verständlicher formuliert, wird ein Pod mit neuer Softwareversion lauffähig gemacht und nachdem dieser lauffähig ist, wird einer der Pods mit der alten Softwareversion heruntergefahren. Dieser Vorgang wird so lange wiederholt, bis alle Pods auf die neue Softwareversion aktualisiert wurden.

2.3.2 Canary

Die Argo-Rollouts Dokumentationsautoren beschreiben ein Canary Deployment so, dass nur ein Bruchteil der Nutzer Zugriff auf die neue Softwareversion erhält und dieser Nutzeranteil kontinuierlich ansteigt, bis festgestellt wurde, dass die Softwareversion korrekt läuft. Danach findet die flächendeckende Akutalisierung aller Services auf die neue Softwareversion statt, zu der alle Nutzer Zugang erhalten. (Vgl. [**ArgoRolloutsCanary2026**]) Danilo Sato erklärt in den Fußnoten seiner Beschreibung für Canary Releases die Herkunft des Namens dieser Strategie. Er beschreibt, dass Minenarbeiter einen Kanarienvogel als Warnsignal in die Kohleminen mitgenommen haben. (Vgl. [**Sato2014**])

2.4 Site Reliability Engineering und dessen Konzepte

2.5 Monitoring und Observability

Kapitel 3

Konzeption und Methodik

Als sinnbildliches Szenario wurde ein Online-Shop gewählt. Die Architektur des Systems besteht aus zwei Microservices, jeweils ein Repräsentant für den Shop und für die Transaktionen. Zwischen den Services besteht technisch keine Abhängigkeit. Im Microservice für die Transaktionen wird ein simulierter Fehler injiziert, während der Shop-Microservice als Referenz dient, um gegebenenfalls infrastrukturelle Fehler erkennbar zu machen, welche nicht auf die injizierten Fehler zurückzuführen sind. Da es sich hierbei um eine nutzerzentrierte Anwendung handelt, werden zwei Fehlerszenarien überprüft. Einerseits die Injektion einer Fehlerrate, in dem der Service einen internen Serverfehler produziert. Andererseits die Simulation verlängerter Antwortzeit. Es wurde jeweils überprüft, wie lange die jeweilige Analyse benötigt, den Fehler zu erkennen und anschließend den stabilen Zustand widerherzustellen. Weiter wurde berechnet, wie hoch der Verbrauch des Fehlerbudgets innerhalb des getesteten Zeitfensters war.

3.1 Systemarchitektur

Das System wurde in einem AWS EKS Cluster mit zwei m7i-flex.large Nodes aufgesetzt. Diese wurden jeweils dediziert für die Ausführung der Monitoring-Software und Lasttests und die Ausführung der zu testenden Services konfiguriert. Dies verhindert, dass die Messungen durch Konkurrenz um Hardware-Ressourcen beeinflusst werden. Abbildung 3.1 veranschaulicht diesen Zustand noch einmal tiefergehend. Hinzuzufügen ist bei der Systemarchitektur, dass Cilium als Service-Mesh konfiguriert wurde. Dies hätte das Monitoring für die Nutzung der Services

von außerhalb des Clusters vereinfacht. Da die Lasttests jedoch über den Cluster-internen DNS aufgelöst wurden, spielt die Implementierung dessen hier keine weitere Rolle. Die zu testende Applikation besteht aus zwei JVM-basierten Mi-

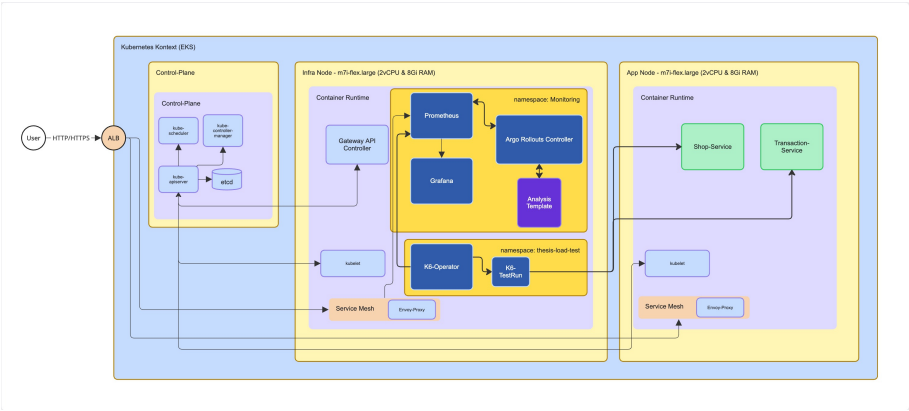

Abbildung 3.1: Systemarchitektur: EKS Cluster Versuchsaufbau

croservices, welche sinnbildlich einen Online-Shop abbilden. Hierfür wurde als Server-Framework Ktor verwendet. Um Fehler während des Deployment Prozesses zu vermeiden, wurden die Container der Microservices jeweils mit Readiness-Probes und einer Mindest-Ready-Zeit von 20 Sekunden ausgestattet. Dies verhindert, dass die Services Anfragen an Pods weiterleten, die sich im Warmup-Prozess befinden. Weiter wurden die Container mit Pre-Stop Hooks von 20 Sekunden versehen, so wird verhindert, dass Anfragen an Pods geleitet werden, die bereits herunterfahren. Um die Erreichbarkeit der Pods sicherzustellen wurden Liveness-Probes implementiert. Diese Applikationen werden auf der Node mit dem Label *role: app-node* gehostet. Die folgenden Software-Tools wurden so konfiguriert, dass sie auf der Node mit dem Label *role: infra-node* ausgeführt werden. Um das Monitoring zu ermöglichen, wurden Prometheus und Grafana im Cluster deployed. Für die Implementierung der jeweiligen Deployment Strategie wurde Argo-Rollouts verwendet. Dies ermöglicht in Verbindung mit Prometheus die SLO-gesteuerte Analyse während des Deployment Vorgangs. Um die Nutzerlast auf den jeweiligen Service zu simulieren wurde K6 mit Constant-Arrival-Rate verwendet. Dies garantiert, dass die Services eine konstant gleichbleibende Last, unabhängig von der Antwortzeit bearbeiten müssen.

3.2 Theoretisches Modell

Rein mathematisch lässt sich bereits beweisen, dass Canary-Releases einen Vorteil beim Verbrauch des Fehlerbudgets gegenüber Rolling Updates haben, in dem Sinne, dass bei gleicher Art des Fehlers, Nutzer kontinuierlich gesteigerten Zugriff auf die neue Softwareversion erhalten. Genauer erklärt am Beispiel: Es wird ein Fehler in der Softwareversion ausgerollt, der in zwei Prozent aller Fälle einen Serverfehler verursacht. Für Rolling Updates erhalten während und nach der Bereitstellung alle Nutzer Zugang zu der neuen fehlerhaften Version, der Einfluss auf den Verbrauch des Fehlerbudgets spiegelt sich direkt wider. Bei Canary Updates werden während des Bereitstellungsprozesses kontinuierlich mehr Nutzer auf die fehlerhafte Version Zugriff erhalten, demnach spiegelt sich während des Deployment Prozesses der Einfluss auf den Verbrauch des Fehlerbudgets anteilig wider. Erst mit dem Abschluss des Canary Releases spiegelt sich der Einfluss direkt auf das Fehlerbudget wider. Weiter ist logisch herzuleiten, dass die Detektionszeit für den Fehler sinkt, wenn sich die Analyse auf die Canary-Version beschränkt, anstatt den Fehler im gesamten System zu überprüfen. Diese Arbeit analysiert den Faktor, um den die Detektionszeit und der Verbrauch des Fehlerbudgets, bei gleicher zeitlicher Analyseintervallrate zwischen Rolling Update und Canary Release mit globaler und isolierter Aggregation sinkt.

3.3 Parameter zur Analyse

Für die Erhebung der Daten wurden jeweils fünf Testläufe über 30 Minuten absolviert. Jeder Service war dabei einer Last von 1200 Anfragen pro Sekunde ausgesetzt. Die injizierten Fehler wurden mittels Umgebungsvariablen realisiert. Da Rolling Updates nativ keine Möglichkeit der Analyse bieten, habe ich mich dazu entschieden, das Alerting von Grafana zu verwenden.
Für die Gewichtung des Datenverkehrs wurden folgende Schritte definiert, nach dem Erhöhen wurde das System für jeweils 5 Minuten überwacht, bevor der nächste Schritt erfolgte:

- 10%
- 50%

- 75%
- 100%

3.3.1 Fehlerfreier Zustand des Systems

Der Zustand der Applikation wurde zuerst ohne injizierte Fehler analysiert, basierend darauf wurde die Definition der SLO's erstellt. Die für diese Arbeit wichtigen Definitionen umfassen:

- eine Verfügbarkeit von 99%
- eine Antwortzeit von 15ms für 95% aller erfolgreichen Anfragen

und beschreiben einen rollierenden Zeitraum von 30 Minuten, im Sinne der Testdauer.

3.3.2 Fehlerszenario A

In Fehlerszenario A wurde der Transaktions-Microservice so konfiguriert, dass er bei der Beantwortung einer Anfrage in 5% der Fälle einen internen Serverfehler meldete. Die zu überprüfende Metrik im Hinblick auf das SLO, ist das Verhältnis fehlerhafter beantworteter Anfragen zur Summe aller Anfragen.

3.3.3 Fehlerszenario B

In Fehlerszenario B wurde der Transaktions-Microservice so konfiguriert, dass er bei der Beantwortung einer Anfrage zusätzlich zur normalen Antwortzeit 15ms warten musste. Die zu überprüfende Metrik ist die Antwortzeit über 95% aller Anfragen, die ohne Fehler beantwortet wurden.

3.3.4 Analyseintervalle

Um ein einheitliches Analyse-Verfahren zu garantieren, wurden die Werte für die Analyseintervalle für alle Analysemethoden vereinheitlicht. Alle 60 Sekunden findet die Überprüfung der Metrik statt. Während für die Analysistemplates ein Feh-

lerlimit von eins gesetzt wurde, was eine einmalige Überschreitung des Schwellwerts zulässt, wurde der Alertmanager genauso konfiguriert, sodass er bei der ersten Schwellwertüberschreitung den Pending Status annimmt, demnach zulässt und erst bei der zweiten Schwellwertüberschreitung den alarmierten Zustand auslöst.

Kapitel 4

Evaluation

Für die Fehlerszenarien wurden die Zeit bis zur Detektion und die Zeit bis zur Wiederherstellung des stabilen Zustands mithilfe der Kubernetes Events bestimmt. Weiter werden die einzelnen Testläufe im zeitlichen Verlauf nebeneinander dargestellt und abschließend werden die gemittelten Werte der unterschiedlichen Deployment Strategien im Kombinationsdiagramm miteinander verglichen.

4.1 Analyse der injizierten Fehlerrate

4.1.1 Mittlere Detektionszeit und Mittlere Wiederherstellungszeit

Abbildung 4.1 zeigt, dass die Zeit bis zur Detektion für Rolling Updates im Vergleich zu den Canary Methoden mit rund 3,3 Minuten am geringsten war. Gefolgt von der Canary Methode mit isolierter Metrikanalyse mit rund 8 Minuten, am längsten benötigte die Canary Methode mit globaler Analysemetrik, hier betrug die Zeit bis zur Detektion im Schnitt 12 Minuten. Die geringste Wiederherstellungszeit erreichte die Canary Methode mit isolierter Metrikanalyse, im Durchschnitt betrug die Zeit rund eine halbe Minute. Die zeitlichen Unterschiede lassen sich mit dem Versuchsaufbau erklären. Bei den Rolling Updates wurde der Fehler sofort erkennbar, da 5% aller Anfragen an das System fehlschlugen. Der zeitliche Unterschied zwischen den Canary Release Methoden lässt sich mit der verwendeten Analysemetrik begründen. Für die globale Aggregation musste die Gewichtung des Datenverkehrs erst einen signifikanten Schwellwert überschreiten, dass die

Fehler nicht von den fehlerfreien Pods überlagert wurden. Die isolierte Analyse stellte hingegen das direkte Verhältnis der fehlerhaften Anfragen zu den Gesamtanfragen an die Canary Version gegenüber und konnte daher einen zeitlichen Vorteil erlangen. Diskutiert wird später dennoch, weshalb während der initialen 10% Gewichtung keine Fehler erkannt wurden, obwohl diese mathematisch Vorkommen sollten. Die Canary Methode mit globaler Analysemetrik stellte den stabilen Zustand innerhalb von rund einer Minute wieder her. Das Rolling Update benötigte für die Wiederherstellung des stabilen Zustands fast zwei Minuten. Die Wiederherstellungszeiten lassen sich in Zusammenhang mit der Anzahl an Pods bringen, die ausgetauscht werden mussten, um die fehlerfreie Version wieder lauffähig zu machen. Die Rolling Updates mussten der Reihe nach alle Pods ersetzen, während bei den Canary Release Methoden noch fehlerfreie Pods lauffähig waren. Der Zeitunterschied von isolierter und globaler Analysemetrik lässt sich weiter in Zusammenhang mit den fehlerfrei laufenden Pods bringen. Die Canary Methode mit isolierter Metrikanalyse detektierte die Fehler im zweiten Schritt, hier waren 50% User-Traffic auf die neue Version umgeleitet und die fehlerfreie Pod Anzahl betrug zwei. Die Canary Methode mit globaler Analysemetrik detektierte den Fehler erst im dritten Schritt mit 75% User-Traffic, die fehlerfreie Pod Anzahl betrug eins.

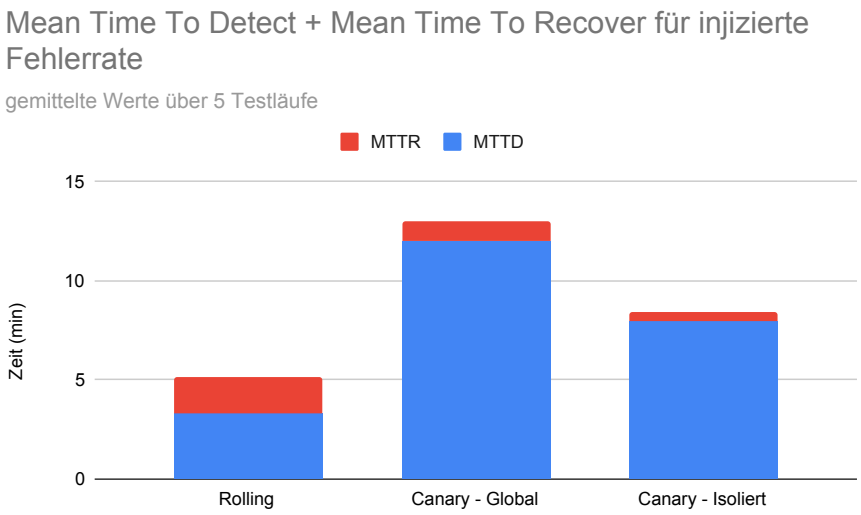

Abbildung 4.1: Summe der Zeit bis zur Detektion und der Zeit bis zur Wiederherstellung für injizierte Fehlerrate

4.1.2 Die einzelnen Testläufe im zeitlichen Verlauf

Die Diagramme zeigen den globalen Einfluss der injizierten Fehlerrate auf das System. Beginnend mit dem Vergleich der einzelnen Testläufe für das Rolling Update zeigt Abbildung 4.2, dass die Fehlerrate den Maximalwert von 5% innerhalb von 5 Minuten erreichte und dieser nach Abschluss des Rollbacks wieder auf null sank.

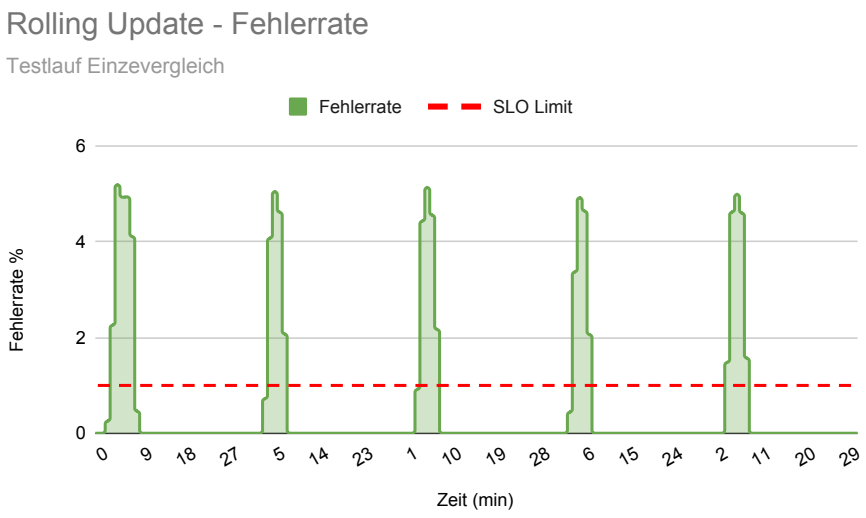

Abbildung 4.2: Fehlerrate Rolling Update im Einzelvergleich

In Abbildung 4.3 wird ersichtlich, dass die Canary Release Strategie mit globaler Metrikanalyse einen Maximalwert von 2,3% Fehlerrate innerhalb von 13 Minuten erreichte. Auffällig ist der erste Testlauf, der nach elf Minuten seinen Peak von 1,1% Fehlerrate erreichte und im Gegensatz zu den folgenden Testläufen direkt zurückgerollt wurde. Inwiefern die Analyse hier schneller reagiert, wird später diskutiert.

Während beide vorherigen Deployment Strategien das SLO-Limit überschritten, zeigt Abbildung 4.4, dass die isolierte Analysemetrik das SLO-Limit erfolgreich über alle Testläufe eingehalten hat. Hier wurden die Maximalwerte im Schnitt innerhalb von neun Minuten erreicht.

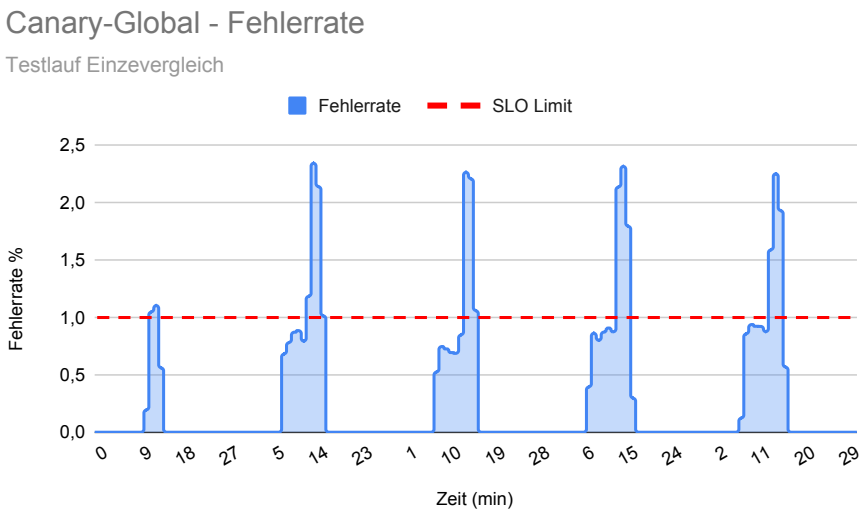

Abbildung 4.3: Fehlerrate Canary Release globaler Metrikanalyse im Einzelvergleich

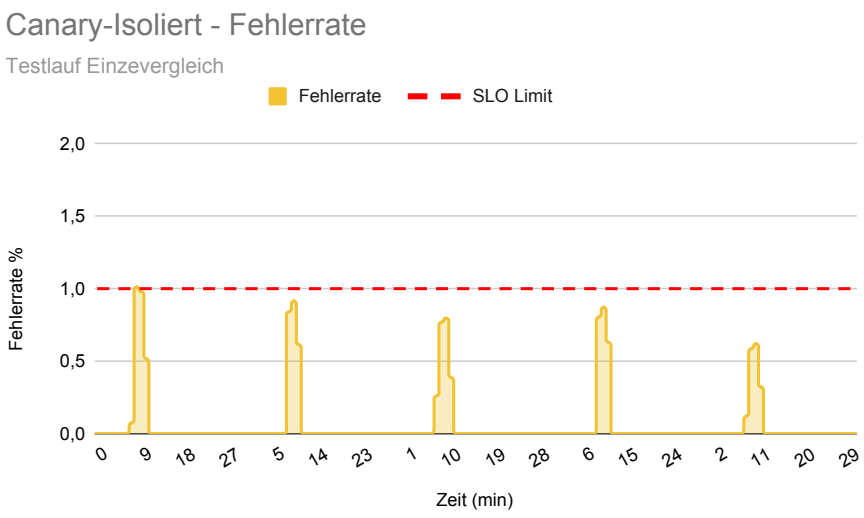

Abbildung 4.4: Fehlerrate Canary Release isolierter Analysemetrik im Einzelvergleich

4.1.3 Die gemittelten Werte der Deployment Strategien im Vergleich

Deutlicher werden die ermittelten Werte im direkten Vergleich der Deployment Strategien. In Abbildung 4.5 wird der Zusammenhang aus Zeit bis zur Detektion und Einfluss der injizierten Fehlerrate für die unterschiedlichen Deployment Strategien stärker ersichtlich, als bei der Einzelbetrachtung. Während das Rolling Update bereits den Wiederherstellungsprozess der stabilen Version abgeschlossen hatte, entstanden die Fehler der Canary Methoden erst. Dafür begrenzte sich der Einfluss der injizierten Fehlerrate bei den Canary Methoden, während das Rolling Update die vollen 5% injizierte Fehlerrate aufwies.

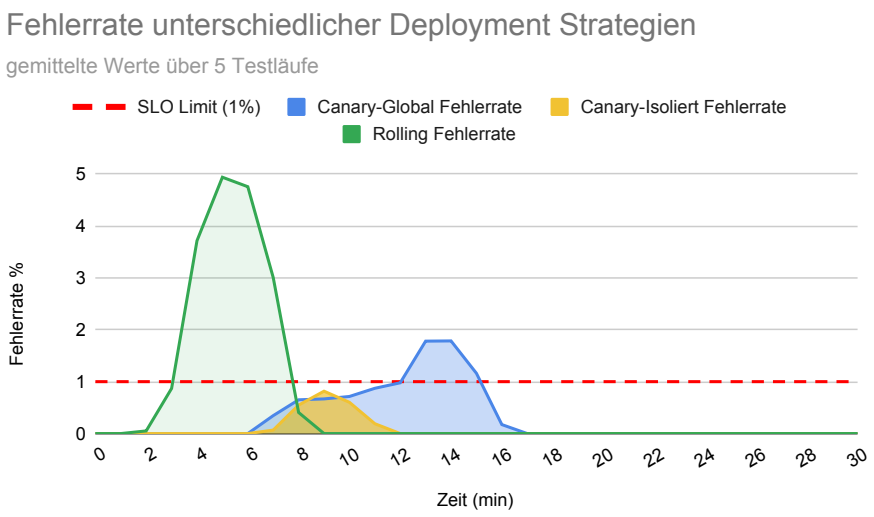

Abbildung 4.5: Fehlerrate unterschiedlicher Deployment Strategien

4.2 Analyse der injizierten Latenz

4.2.1 Mittlere Detektionszeit und Mittlere Wiederherstellungszeit

Abbildung 4.6 zeigt auch hier, dass das Rolling Update die geringste Zeit von der Fehlerinjektion bis zur Wiederherstellung des stabilen Zustands benötigte. Im Durchschnitt über alle Testläufe rund 6,9 Minuten. Das Canary Release mit isolierter Analysemetrik benötigte von der Injektion bis zur Wiederherstellung rund 7,3

Minuten, während das Canary Release mit globaler Metrikanalyse mit rund 13,3 Minuten am längsten benötigte. Wie auch im Fehlerszenario A lassen sich diese Zeiten mit dem direkten Einfluss des injizierten Fehlers für das Rolling Update erklären. Gleich gilt auch der Vorteil der isolierten Analyse der Canary Releases gegenüber dem globalen Ansatz, da für die isolierte Metrik, der direkte Einfluss der Canary Version überprüft wurde, hingegen musste bei der globalen Metrikanalyse erst eine ausreichend hohe Gewichtung des Datenverkehrs auf die Canary Version erreicht werden, damit der Fehler erkannt wurde.

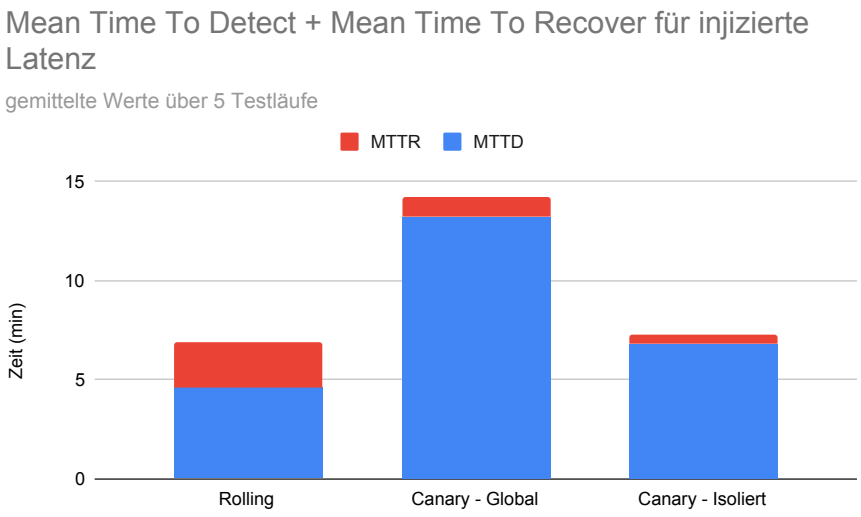

Abbildung 4.6: Summe der Zeit bis zur Detektion und der Zeit bis zur Wiederherstellung für injizierte Latenz

4.2.2 Die einzelnen Testläufe im zeitlichen Verlauf

Die Diagramme zeigen den globalen Einfluss der injizierten Fehlerrate auf das System. Beginnend mit dem Vergleich der einzelnen Testläufe für das Rolling Update zeigt Abbildung 4.7, dass die Latenz Maximalwerte von über einer Sekunde Antwortzeit betrug. Dies ist mit blockierenden Threads zu erklären. Die Softwareversion hat es nicht geschafft die Anfragen in genügend geringer Zeit zu beantworten und die Pods wurden durch die Überlastung von CPU-Ressourcen kontinuierlich neu gestartet. Diese Unerreichbarkeit der Services ist als Downtime zu bewerten.

In Abbildung 4.8 wird ersichtlich, dass die Canary Release Strategie mit globaler Metrikanalyse einen Maximalwert von bis zu 290 Millisekunden an Antwortzeit

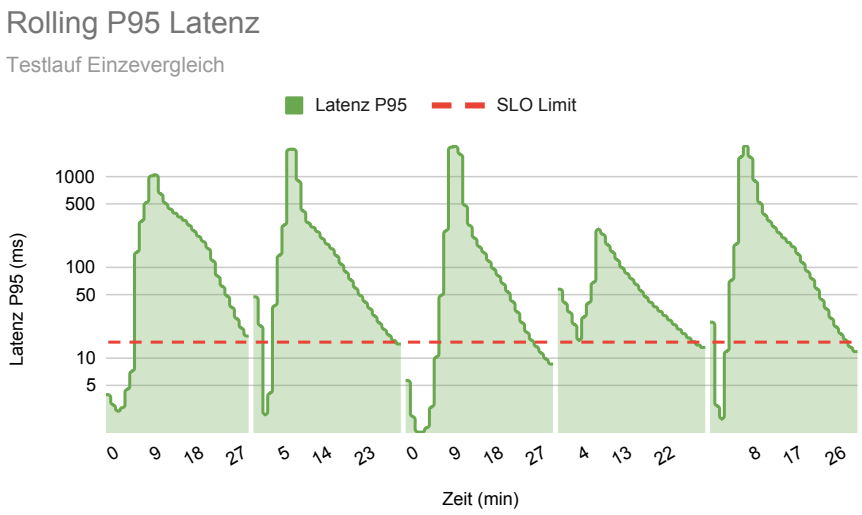

Abbildung 4.7: Latenz Rolling Update im Einzelvergleich

benötigte. Dies entspricht einer Steigerung um den Faktor 20 der erlaubten Antwortzeit entsprechend des SLO.

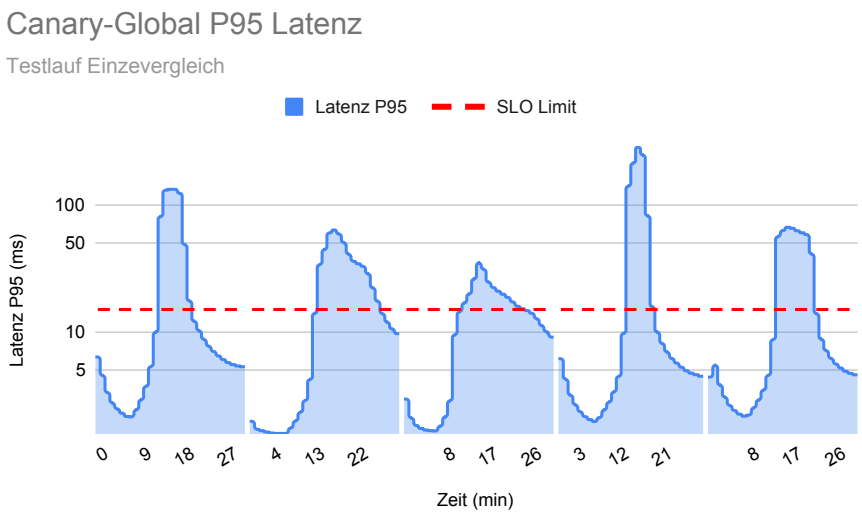

Abbildung 4.8: Latenz Canary Release globaler Metrikanalyse im Einzelvergleich

Die beiden vorherigen Deployment Strategien überschritten das SLO-Limit deutlich, Abbildung 4.9 zeigt, dass die isolierte Analysemetrik das SLO-Limit erfolgreich über alle Testläufe eingehalten hat. Auffällig sind im Diagramm einzig die Warm-Up Phasen während des Deploymentstarts.

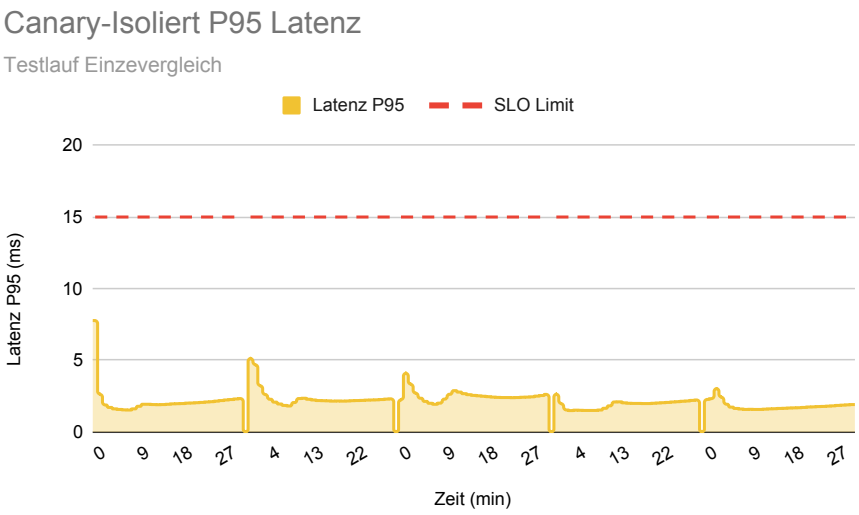

Abbildung 4.9: Latenz Canary Release isolierter Analysemetrik im Einzelvergleich

4.2.3 Die gemittelten Werte der Deployment Strategien im Vergleich

Der direkte Vergleich der Deployment Strategien bringt die Überlegenheit des isolierten gegenüber des globalen Analyseansatzes und der Analyse des Rolling Updates deutlich zum Vorschein. Die globale Analyse des Canary Releases und das Rolling Update überschritten das gesetzte Limit bei Weitem. Während die isolierte Metrikanalyse des Canary Releases keinen Einfluss auf das Gesamtsystem aufweist.

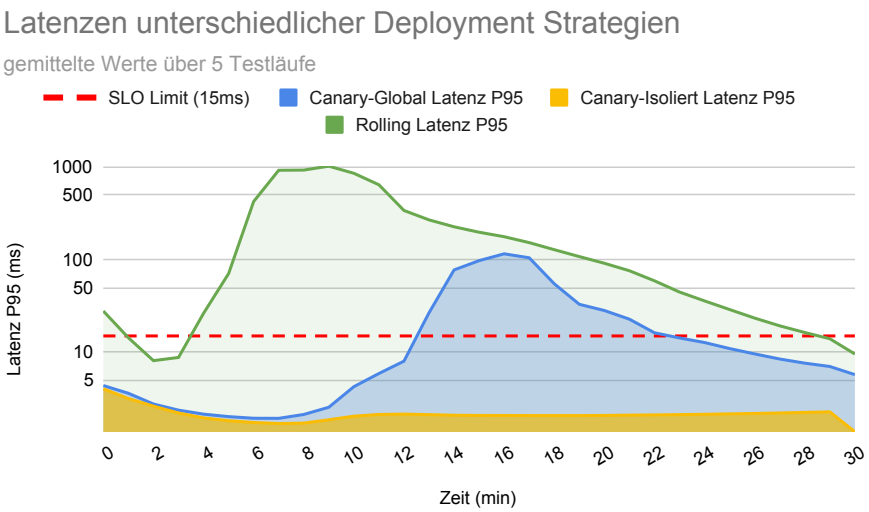

Abbildung 4.10: Latenzen unterschiedlicher Deployment Strategien

4.3 Fehlerbudget Verbrauch pro Deployment Strategie

4.3.1 Fehlerszenario A

Abbildung 4.11 zeigt den Einfluss der Analysemetrik und der Deployment Strategie auf den Verbrauch des Fehlerbudgets. Den geringsten Verbrauch erreichte die Canary Release Strategie mit isolierter Analyse. Der Bedarf betrug 7,4% des Gesamtbudgets. Das Canary Release mit globaler Analyse erreichte einen Bedarf von 30,42% am Gesamtbudget. Den höchsten Verbrauch des Fehlerbudgets bedurfte das Rolling Update mit 59,14%. In diesem speziellen Szenario verringerte die Canary Release Strategie mit globaler Analysemetrik den Verbrauch des Fehlerbudgets im Gegensatz zum Rolling Update um 28,71 Prozentpunkte und die isolierte Analyse erreichte eine Verringerung des Budgetverbrauchs gegenüber dem Rolling um 51,72 Prozentpunkte. Weiter ist eine Verringerung des isolierten gegenüber dem globalen Ansatz um 23,01 Prozentpunkte festzuhalten.

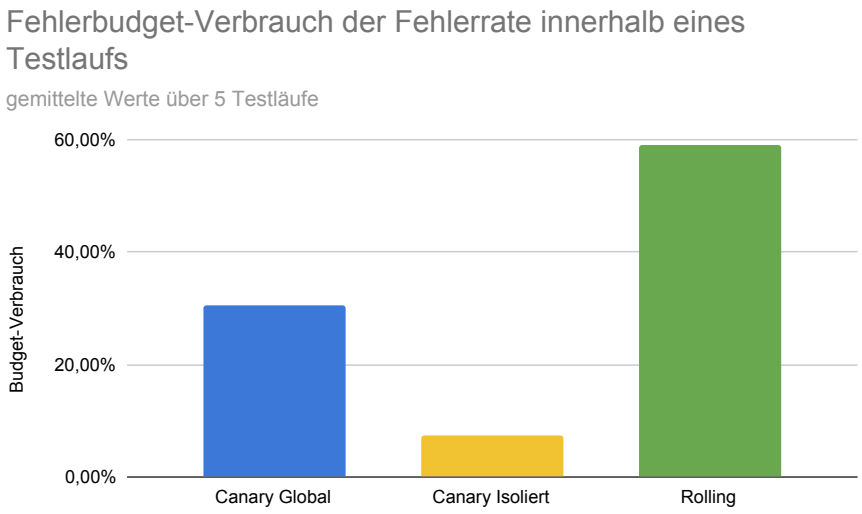

Abbildung 4.11: Verbrauch des Fehlerbudgets unterschiedlicher Deployment Strategien bei injizierter Fehlerrate über die Testdauer

4.3.2 Fehlerszenario B

Abbildung 4.12 zeigt ebenfalls den Einfluss der Analysemetrik und Deployment Strategie hinsichtlich des Verbrauchs des Fehlerbudgets. Während der geringste

Bedarf von 0,25% am Fehlerbudget durch die isolierte Analysemetrik des Canary Releases erreicht wurde, verbrauchte die globale Analyse 2,59%. Das Rolling Update stellte mit rund 26% den höchsten Bedarf am Fehlerbudget. Die Einsparung des Fehlerbudgets von Canary Release mit globaler Analyse beläuft sich auf 23,4 Prozentpunkte gegenüber dem Rolling Update. Das Canary Release mit isolierter Analyse erreichte eine Einsparung von 25,74 Prozentpunkten gegenüber dem Rolling Update. Die Verringerung der Canary Release Strategie mit isolierter gegenüber globaler Analyse beläuft sich auf 2,34 Prozentpunkte.

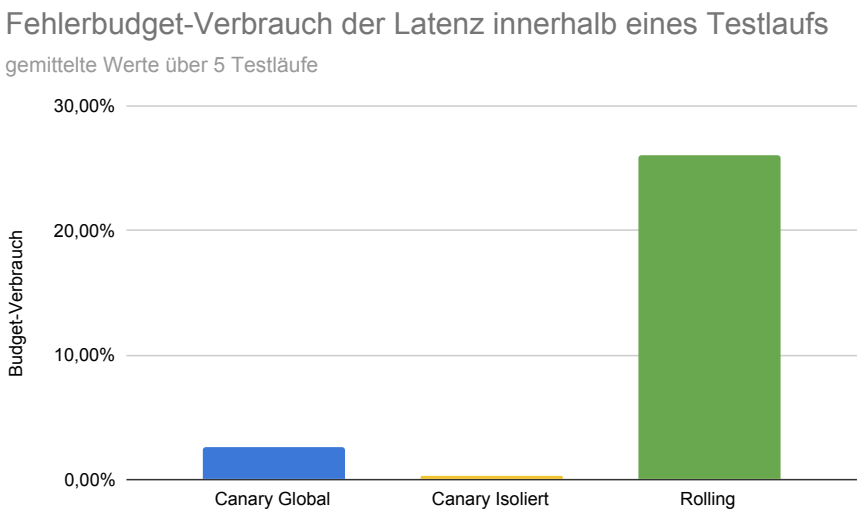

Abbildung 4.12: Verbrauch des Fehlerbudgets unterschiedlicher Deployment Strategien bei injizierter Latenz über die Testdauer

Kapitel 5

Diskussion

5.1 Der erste Testlauf der injizierten Fehlerrate für das Canary Release mit globaler Metrikanalyse

Beim Erstellen der Graphen für die einzelnen Testläufe war dieser direkt auffällig. Offensichtlicher wurde die Auffälligkeit nach der Erstellung der Analyse der Canary Releases mit isolierter Metrik. Die Werte stimmten beinahe überein. Von der Erklärung abgesehen, dass die Messwerte hier zufällig innerhalb von zwei Minuten den Schwellwert geringfügig überschritten, vermute ich, dass die Beachtung der JVM-Warmup-Zeiten eine Verbesserung der Detektionszeit hervorgerufen hätte, in dem Sinne, dass die Analyse mit einer initialen Verzögerung Fehler schneller detektiert hätte, da die ersten Pods bereits lauffähig und ansprechbar gewesen wären.

5.2 Nicht gemessene Fehler während der ersten Canary Phase

Bei der Analyse der Daten ist aufgefallen, dass praktisch keine Fehlerrate während der initialen Canary Phase, der Gewichtung des Datenverkehrs von 10%, erfasst wurde. Mathematisch betrachtet, sollten mit 1200 Anfragen pro Sekunde, einer Gewichtung von 10% und einer Fehlerrate von 5%, sechs Fehler pro Sekunde und dementsprechend 360 Fehler pro Minute auftreten, jedoch erfasste

weder die globale, noch die isolierte Analyse einen einzigen Fehler für die Gewichtung während der Zeit von fünf Minuten. Ein möglicher Grund für das Nicht-Erfassen der globalen Analyse dieser Fehlerrate kann statistische Irrelevanz sein. 360 Fehler zu 72.000 Anfragen pro Minute ist für die Aggregation der Metrik möglicherweise nicht signifikant genug. Andernfalls erklärt das die Nicht-Erkennung der isolierten Analyse nicht, da hier 360 Fehler zu 7.200 Anfragen stehen, was genau der injizierten Fehlerrate entspricht. Eine genaue Erklärung der Nicht-Erkennung lässt sich aus meiner Sicht nicht treffen.

5.3 Detektionszeit in Zusammenhang des Fehlerbudgetverbrauchs

Die Berechnung der Zeit bis zur Detektion des Fehlers zeigt deutlich, dass die Rolling Updates Analyse den Fehler am schnellsten erkannt hat. Jedoch hat diese Deployment Strategie auch den größten Verbrauch am Fehlerbudget. Wie im oberen Abschnitt beschrieben, wurden für die initiale Phase des Canary Releases jedoch kaum bis keine Defekte der Softwareversion festgestellt. Würde die Zeit der initialen Phase von der Detektionszeit abgezogen werden, so hätte die Canary Release Strategie mit isolierter Analyse eine geringere Detektionszeit gegenüber dem Rolling Update. Andersherum hätte die Datenverkehr Gewichtung innerhalb der initialen Phase auch schneller erhöht werden können, um einen statistisch signifikanten Schwellwert zu überschreiten und schneller Fehler zu provozieren. Letztlich zeigen die Daten der Detektionszeit im Zusammenhang mit dem Fehlerverbrauch, dass eine schnellere Detektionszeit nicht direkt mit einer Ersparnis des Fehlerbudgets einhergehen, sondern dass der Anteil betroffener Nutzer den entscheidenden Anteil am Verbrauch des Fehlerbudgets trägt.

Kapitel 6

Fazit

Abschließend werden die Forschungsfrage beantwortet und ein Ausblick über mögliche sich dieser Arbeit anschließende Forschungsprojekte benannt.

6.1 Beantwortung der Forschungsfrage

Im speziellen Versuchsaufbau von 1200 Anfragen pro Sekunde auf den jeweiligen Service und injizierten Fehlern von fünf Prozent Fehlerrate und 15 Millisekunden zusätzlicher Latenz, konnte das Canary Release mit SLO basierter Analyse bei gleicher überprüfter Metrik eine Reduzierung des Fehlerbudgetverbrauchs gegenüber Rolling Updates von 28% für die injizierte Fehlerrate und 23% für injizierte Latenz erreichen. Durch den Einsatz isolierter Analysen für Canary Releases war es möglich das Fehlerbudget um 51% bei injizierter Fehlerrate und 25% bei injizierter Latenz zu verringern.

6.2 Ausblick

In weiteren analytischen Arbeiten kann überprüft werden, inwiefern sich die Detektionszeit bei feinerer Gewichtung des Datenverkehrs verringern lässt, welchen Einfluss das Analyseintervall auf die Detektionszeiten hat oder inwiefern sich Deployments mit Blue-Green Strategie unterscheiden. Weiter könnte der Kostenfaktor analysiert werden, der durch den Mehraufwand dedizierter Monitoring Nodes entsteht und anschließend in Verhältnis zur Ersparnis gesetzt werden.

Anhang A

Eigenständigkeitserklärung

Hiermit erkläre Ich, dass die vorliegende Arbeit selbstständig und nur unter Verwendung der angegebenen Literatur und Hilfsmittel angefertigt habe. Stellen, die wörtlich oder sinngemäß aus Quellen entnommen wurden, sind als solche kenntlich gemacht. Diese Arbeit wurde in gleicher oder ähnlicher Form noch keiner anderen Prüfungsbehörde vorgelegt.

Borna, den 24.03.2026 Paul Fuchs